

多传感器融合第一章第三题实现讲解



主讲人 周朋伟



第三题

Generalized-ICP 实现思路讲解

给定存在的两组点云集合： $\hat{A} = \{\hat{a}_i\}$ 和 $\hat{B} = \{\hat{b}_i\}$

每个测量点假设都是服从高斯分布的，记为如下形式：

$$a_i \sim \mathcal{N}(\hat{a}_i, C_i^A) \quad b_i \sim \mathcal{N}(\hat{b}_i, C_i^B)$$

$$\hat{b}_i = \mathbf{T}^* \hat{a}_i$$

由于我们假设两个集合中的点是服从独立的高斯分布，当 \mathbf{T}^* 为最优解时，误差函数将会服从如下形式的高斯分布：

$$\begin{aligned} d_i^{(\mathbf{T}^*)} &\sim \mathcal{N}\left(\hat{b}_i - (\mathbf{T}^*)\hat{a}_i, C_i^B + (\mathbf{T}^*)C_i^A(\mathbf{T}^*)^T\right) \\ &= \mathcal{N}\left(0, C_i^B + (\mathbf{T}^*)C_i^A(\mathbf{T}^*)^T\right) \end{aligned}$$

之后我们为了求解最优解，只需使得概率乘积达到最大：

$$\mathbf{T} = \operatorname{argmax}_{\mathbf{T}} \prod_i p\left(d_i^{(\mathbf{T})}\right) = \operatorname{argmax}_{\mathbf{T}} \sum_i \log\left(p\left(d_i^{(\mathbf{T})}\right)\right)$$

将高斯分布展开之后，等价于最小化下式：

$$\mathbf{T} = \operatorname{argmin}_{\mathbf{T}} \sum_i d_i^{(\mathbf{T})^T} \left(C_i^B + \mathbf{T}C_i^A\mathbf{T}^T\right)^{-1} d_i^{(\mathbf{T})} \quad \text{其中: } d_i^{(\mathbf{T})} = (b_i - \mathbf{T}a_i)$$

雅克比矩阵

$$f(\mathbf{x}) = \operatorname{argmin}_{\mathbf{T}} \sum_i \left\| \left(C_i^B + \mathbf{T}_{\text{last}} C_i^A \mathbf{T}_{\text{last}}^T \right)^{-1} (b_i - \mathbf{T} a_i) \right\|^2$$

使用李代数来推导雅克比矩阵的形式: $\text{se3_pose} = \{ \varphi_1, \varphi_1, \varphi_1, x, y, z \}$.

对于旋转部分利用左扰动模型求导

$$\frac{\partial(\mathbf{R} \mathbf{a}_i + \mathbf{t})}{\partial \varphi} = -(\mathbf{R} \mathbf{a}_i)^\wedge \quad \frac{\partial(\mathbf{R} \mathbf{a}_i + \mathbf{t})}{\partial \mathbf{t}} = \mathbf{I}$$

$$\mathbf{J}_{[3,6]} = \left(C_i^B + \mathbf{T}_{\text{last}} C_i^A \mathbf{T}_{\text{last}}^T \right)^{-1} \{ (\mathbf{R} \mathbf{a}_i)^\wedge, -\mathbf{I} \}$$

$$\mathbf{J}(\mathbf{x})^T \mathbf{J}(\mathbf{x}) \Delta \mathbf{x} = -\mathbf{J}(\mathbf{x})^T f(\mathbf{x})$$

$$\mathbf{H} \Delta \mathbf{x} = \mathbf{g} \quad \text{计算增量, 迭代更新。}$$

协方差矩阵

计算每个点的协方差矩阵后，做SVD分解，按照如下形式进行归一化。

$$C_i^B = \mathbf{U}_{bi} \cdot \begin{pmatrix} \epsilon & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{pmatrix} \cdot \mathbf{V}_{bi}^T$$
$$C_i^A = \mathbf{U}_{ai} \cdot \begin{pmatrix} \epsilon & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{pmatrix} \cdot \mathbf{V}_{ai}^T$$

其中: ϵ 表示法向量计算出来的不确定度，设定成常数如: $1e-2$ 。




Fig. 1. illustration of plane-to-plane

Generalized-ICP 直观解释，绿色平面中垂直部分的点全部是错误的对应的关系，但是由于这部分点的表面分布不一致，最终累加起来的协方差矩阵将会是各向同性(各个方向的分布近似相等)。其对于误差函数的影响很小。

计算loss和雅克比矩阵

```
const auto& mean_A = source_>at(i).getVector4fMap();

const auto& cov_A = source_covs[i];

const auto& mean_B = target_>at(target_index).getVector4fMap();

const auto& cov_B = target_covs[target_index];

Eigen::Vector4f mean_A_temp = mean_A;
Eigen::Vector4f transed_mean_A = trans * mean_A;
Eigen::Vector4f d = mean_B - transed_mean_A;
Eigen::Matrix4f RCR = cov_B + trans * cov_A * trans.transpose();
RCR(3, 3) = 1;

Eigen::Matrix4f RCR_inv = RCR.inverse();
Eigen::Vector4f RCRd = RCR_inv * d;

Eigen::Matrix<float, 4, 6> dtdx0 = Eigen::Matrix<float, 4, 6>::Zero();
dtdx0.block<3, 3>(0, 0) = skew(transed_mean_A.head<3>());

dtdx0.block<3, 3>(0, 3) = -Eigen::Matrix3f::Identity();

Eigen::Matrix<float, 4, 6> jlossexp = RCR_inv * dtdx0;
int n = count++;

losses[n] = RCRd.head<3>();
Js[n] = jlossexp.block<3, 6>(0, 0);
```

迭代求解

```
for(int i = 0; i < max_iterations_; i++) {
    nr_iterations_ = i;
    update_correspondences(x0);
    Eigen::MatrixXf J;
    Eigen::VectorXf loss = loss_ls(x0, &J);

    Eigen::Matrix<float, 6, 1> delta =
        solver.delta(loss.cast<double>(), J.cast<double>()).cast<float>();

    Eigen::Isometry3f x0_ = Eigen::Isometry3f::Identity();
    x0_.linear() = Sophus::SO3f::exp(x0.head<3>()).matrix();
    x0_.translation() = x0.tail<3>();

    Eigen::Isometry3f delta_ = Eigen::Isometry3f::Identity();
    delta_.linear() = Sophus::SO3f::exp(delta.head<3>()).matrix();
    delta_.translation() = delta.tail<3>();

    Eigen::Isometry3f x1_ = delta_.inverse() * x0_;

    x0.head<3>() = Sophus::SO3f(x1_.linear()).log();
    x0.tail<3>() = x1_.translation();

    if(is_converged(delta)) {
        converged_ = true;
        break;
    }
}
```

可尝试不同的降采样策略：

- Voxel sampling
- Random sampling
- Skip sampling

可关闭运动畸变部分的旋转部分，只删除起始和终止附近一定角度的点云

```
float start_orientation = atan2(origin_cloud_ptr->points[0].y, origin_cloud_ptr->points[0].x);  
pcl::transformPointCloud(*origin_cloud_ptr, *origin_cloud_ptr, transform_matrix);
```

由于初始的第一个点的角度值计算出来并不稳定，实测大约会在 $0.3^{\circ} \sim 9^{\circ}$ 附近变化，这样会给初始值带来额外的误差。

Reference:

https://github.com/SMRT-AIST/fast_gicp

<https://github.com/PointCloudLibrary/pcl/blob/master/registration/include/pcl/registration/impl/gicp.hpp>



深蓝学院
shenlanxueyuan.com

感谢各位聆听 !
Thanks for Listening

